



SVEUČILIŠTE JOSIPA JURJA STROSSMAYERA U OSIJEKU

FAKULTET PRIMIJENJENE MATEMATIKE I INFORMATIKE

Sveučilišni prijediplomski studij Matematika i računarstvo

Izrada sustava za predikciju Alzheimerove bolesti

ZAVRŠNI RAD

Mentor:

izv. prof. dr. sc. Domagoj Matijević

Kandidat:

Lana Maltar

Osijek, 2025

Sadržaj

1	Uvod	1
2	Motivacija i pozadina istraživanja	3
2.1	Alzheimerova bolest i važnost rane detekcije	3
2.2	Strojno i duboko učenje u medicini	3
3	Primjena strojnog učenja u predikciji Alzheimerove bolesti	6
3.1	Skup podataka	6
3.2	Priprema podataka	7
3.3	Odabrani algoritam	8
3.4	Proces treniranja	9
3.5	Rezultati	10
4	Primjena dubokog učenja u predikciji Alzheimerove bolesti	15
4.1	Skup podataka	15
4.2	Priprema podataka	16
4.3	Arhitektura modela	17
4.4	Proces treniranja modela	18
4.5	Rezultati	19
4.6	Primjena modela u web aplikaciji	22
5	Zaključak	24
	Literatura	26
	Sažetak	28
	Summary	30
	Životopis	32

1 | Uvod

Alzheimerova bolest je vodeći uzrok demencije i jedna od najčešćih neurodegenerativnih bolesti. Zbog kasnog prepoznavanja simptoma i postupnog razvoja bioloških promjena u mozgu, rana detekcija ima ključnu ulogu u usporavanju napredovanja bolesti i poboljšanju kvalitete života oboljelih.

Cilj završnog rada je izrada prediktivnog sustava za detekciju Alzheimerove bolesti. Sustav se temelji na dva različita pristupa: klasičnim metodama strojnog učenja, koje koriste numeričke demografske i kliničke podatke pacijenata, te dubokim učenjem, gdje se za analizu koriste slike mozga dobivene magnetskom rezonancijom. Nakon razvoja i evaluacije, modeli su integrirani kao ključna komponenta web aplikacije prilagođene jednostavnom korištenju i širokoj dostupnosti.

Rad je strukturiran na sljedeći način. Prvo poglavlje bavi se problematikom i motivacijom istraživanja, s naglaskom na izazove rane detekcije Alzheimerove bolesti te mogućnosti primjene strojnog i dubokog učenja u medicinskoj dijagnostici. Drugo poglavlje posvećeno je modelu strojnog učenja temeljenom na numeričkim podacima pacijenata, dok treće poglavlje donosi opis modela dubokog učenja temeljenog na konvolucijskim neuronskim mrežama te prikaz primjene oba modela u okviru web aplikacije.

2 | Motivacija i pozadina istraživanja

2.1 Alzheimerova bolest i važnost rane detekcije

Jedan od glavnih izazova rane detekcije Alzheimerove bolesti leži u ograničenjima klasičnih dijagnostičkih metoda. Trenutne procjene bolesti oslanjaju se na kliničke testove, neuropsihološke procjene i medicinske slikovne metode, koje su često vremenski zahtjevne i podložne subjektivnim interpretacijama. Osim toga, simptomi u ranim stadijima mogu se zamijeniti s prirodnim procesom starenja, što dodatno otežava preciznu i adekvatnu dijagnozu.

Unatoč napretku medicine, bolest se i dalje najčešće otkriva u kasnim fazama kada su mogućnosti liječenja ograničene, a kvaliteta života oboljelih značajno narušena. Rana detekcija stoga ima ključnu ulogu jer omogućuje pravodobne intervencije koje mogu usporiti napredovanje bolesti i pacijentima pružiti bolju kvalitetu života.

2.2 Strojno i duboko učenje u medicini

Razvoj medicine u posljednjem desetljeću obilježen je sve većom primjenom metoda strojnog i dubokog učenja. Kliničke odluke danas se sve više oslanjaju na analizu velikih količina podataka, a upravljanje takvim podacima klasičnim metodama pokazalo se izazovnim zbog njihove složenosti i velike dimenzionalnosti, što je otvorilo prostor za nove pristupe u analizi podataka.

Strojno učenje omogućuje otkrivanje obrazaca u podacima bez potrebe za ručnim definiranjem značajki, dok duboko učenje dodatno ide korak dalje jer koristi neuronske mreže za automatsko izdvajanje i oblikovanje značajki iz sirovih podataka. Na taj način modeli mogu skalirati na vrlo velike skupove podataka i poboljšavati se kako raste količina dostupnih informacija.

Posebno važnu ulogu u medicini imaju konvolucijske neuronske mreže koje su prilagođene za analizu podataka s prostornom strukturom, poput medicinskih slika. Njihova sposobnost da prepoznaju lokalne obrasce i hijerarhijske strukture čini ih iznimno učinkovitim u područjima poput radiologije, gdje se koriste za klasifikaciju i detekciju anomalija na rendgenskim, CT i MR snimkama. Modeli

temeljeni na konvolucijskim neuronskim mrežama dokazali su da mogu otkriti promjene koje su često nevidljive ljudskom oku, što ih čini posebno korisnima u ranoj dijagnostici bolesti.

Unatoč brojnim ograničenjima, od interpretabilnosti modela do zakonskih regulativa, sve je više pokazatelja da se strojno i duboko učenje uspješno implementiraju u kliničku praksu. Njihov potencijal posebno dolazi do izražaja u bolestima poput Alzheimerove, gdje rana detekcija i predikcija razvoja bolesti mogu imati presudan utjecaj na kvalitetu života pacijenata.

3 | Primjena strojnog učenja u predikciji Alzheimerove bolesti

U ovom poglavlju prikazan je model strojnog učenja koji, koristeći demografske i kliničke značajke iz OASIS longitudinalnog skupa podataka, predviđa prisutnost Alzheimerove bolesti klasificirajući pacijente kao nedementne ili dementne.

U analizu su uključeni podaci o dobi, spolu, socioekonomskom statusu i rezultatima testa MMSE, koji se smatraju ključnim kliničkim pokazateljima kognitivnog zdravlja te omogućuju uvid u moguće rane znakove Alzheimerove bolesti.

U nastavku su prikazani postupci pripreme podataka, odabira algoritma i treniranja modela, kao i analiza dobivenih rezultata.

3.1 Skup podataka

Korišten je OASIS longitudinalni skup podataka (Longitudinal MRI Data in Non-demented and Demented Older Adults), koji sadrži informacije o 150 ispitanika u dobi od 60 do 96 godina. Svaki ispitanik sniman je magnetskom rezonancom tijekom najmanje dvaju posjeta, razdvojenih vremenskim razmakom od najmanje jedne godine, što ukupno čini 373 sesije snimanja. Za svaki posjet dostupne su tri do četiri T1-ponderirane MR snimke.

Sudionici istraživanja bili su dešnjaci, obuhvaćali su muškarce i žene, a klasificirani su u tri glavne skupine:

1. 72 ispitanika ostala su nedementna tijekom cijelog istraživanja,
2. 64 ispitanika bila su dementna već na početnom posjetu i ostala u tom statusu tijekom svih kasnijih snimanja (uključujući 51 osobu s blagim do umjerenim Alzheimerom),
3. 14 ispitanika u početku su bili klasificirani kao nedementni, ali su tijekom kasnijih posjeta pokazali simptome demencije.

Ovaj skup podataka omogućuje longitudinalnu analizu, što ga čini posebno pogodnim za istraživanje razvoja Alzheimerove bolesti i testiranje metoda predikcije.

Skup podataka sadrži ukupno 15 varijabli, a Tablica 3.1 prikazuje njihov popis i kratko objašnjenje.

Varijabla	Opis
Subject ID	Jedinstveni identifikator ispitanika
MRI ID	Jedinstveni identifikator MRI pregleda
Group	Pripadnost klasi: Nedementni, Dementni ili Konvertirani
Visit	Redni broj posjeta ispitanika (1, 2, 3 ...)
MR Delay	Vremenski razmak u danima između prvog i trenutnog MRI snimanja
M/F	Spol ispitanika (M = muški, F = ženski)
Hand	Dominantna ruka ispitanika (R = dešnjak, L = ljevak)
Age	Dob ispitanika izražena u godinama
EDUC	Broj godina formalnog obrazovanja
SES	Socioekonomski status ispitanika
MMSE	Rezultat kognitivnog testa Mini Mental State Examination
CDR	Klinička ljestvica demencije
eTIV	Procijenjeni ukupni intrakranijalni volumen
nWBV	Normalizirani volumen mozga u odnosu na intrakranijalni prostor
ASF	Vrijednost prilagodbe volumena mozga pojedinca prema standardnom moždanom atlasu

Tablica 3.1: Pregled varijabli u OASIS longitudinalnom skupu podataka

3.2 Priprema podataka

Prije treniranja modela provedeno je nekoliko koraka obrade podataka, koji su opisani u nastavku.

Nedostajuće vrijednosti

Varijable *SES* (socioekonomski status) i *MMSE* (Mini-Mental State Examination) sadržavale su nedostajuće vrijednosti. One su popunjene imputacijom pomoću medijana kako bi se smanjio utjecaj ekstremnih vrijednosti. Svi preostali zapisi s nedostajućim podacima uklonjeni su iz skupa.

Uklanjanje varijabli

Varijabla *Hand* (dominantna ruka ispitanika) izostavljena je jer je u skupu imala gotovo homogenu distribuciju (svi ispitanici su dešnjaci) i nije imala dijagnostičku vrijednost.

Kodiranje kategorijskih podataka

Kategorijske varijable pretvorene su u numeričke vrijednosti.

Varijabla *M/F* označava spol ispitanika, pri čemu je vrijednost *M* dodijeljena muškarcima, a *F* ženama. Nakon kodiranja u numerički oblik, muškom spolu dodijeljena je vrijednost 1, a ženskom 0.

Varijabla *Group* označava pripadnost klasi, odnosno kognitivni status ispitanika. Kategorija *Non Demented* označava ispitanike bez znakova demencije i kodirana je vrijednošću 0, dok kategorija *Demented* označava ispitanike s dijagnozom demencije i kodirana je vrijednošću 1.

Kategorija *Converted* spojena je s klasom *Demented* radi uravnoteženja skupova i pojednostavljenja klasifikacije.

Definiranje značajki i ciljne varijable

Kao ulazne značajke (X) korištene su varijable: *MR Delay*, *CDR*, *M/F*, *Age*, *EDUC*, *SES*, *MMSE*, *eTIV*, *nWBV*, *ASF*. Ciljna varijabla (y) bila je *Group* (0 = nedementni, 1 = dementni).

Podjela na skupove

Podaci su podijeljeni u trenirajući (80%) i testni skup (20%), uz stratificiranu podjelu kako bi se očuvala proporcija klasa.

3.3 Odabrani algoritam

Za klasifikaciju pacijenata korištena je logistička regresija. Osnovna ideja modela jest da se vjerojatnost pripadnosti uzorka pozitivnoj klasi modelira pomoću *logističke* (sigmoidne) funkcije:

$$\sigma(x) = \frac{1}{1 + e^{-x}}, \quad \sigma : \mathbb{R} \rightarrow (0, 1).$$

Model funkcija tada poprima oblik

$$h_{\Theta}(x) = \sigma(\Theta^T x) = \frac{1}{1 + \exp(-\Theta^T x)},$$

pri čemu je Θ vektor parametara modela (težina), a po potrebi se uključuje i dodatni slobodni parametar θ_0 .

Logistička funkcija preslikava cijelu realnu os u interval $(0, 1)$, pa izlaznu vrijednost interpretiramo kao vjerojatnost da podatak x pripada klasi 1.

Hiperravnina zadana parametrima Θ predstavlja granicu odlučivanja koja razdvaja prostor značajki na područje u kojem se uzorci klasificiraju kao 0 i područje u kojem se klasificiraju kao 1.

Učenje logističke regresije svodi se na minimizaciju konveksne funkcije cilja:

$$J(\Theta) = - \sum_{i=1}^m \left(y^{(i)} \log(h_{\Theta}(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_{\Theta}(x^{(i)})) \right)$$

pri čemu $y^{(i)} \in \{0, 1\}$ označava stvarnu klasu primjera $x^{(i)}$. Optimizacija se provodi gradijentnim metodama ili sličnim algoritmima, a zbog konveksnosti ciljne funkcije zajamčeno je nalaženje globalnog minimuma.

Radi smanjenja rizika od preučenja, u praksu se uvodi regularizacija. Najčešće se koriste:

1. L1 regularizacija (Lasso) – potiče rijetka rješenja i može eliminirati nebitne značajke,
2. L2 regularizacija (Ridge) – penalizira kvadrat težina, čime se dobiva stabilniji model.

Prednost logističke regresije u medicinskim istraživanjima jest njena interpretabilnost. Koeficijenti Θ mogu se tumačiti kao utjecaj pojedine značajke na vjerojatnost pojave bolesti, što olakšava kliničku primjenu i razumijevanje modela.

U ovom radu logistička regresija implementirana je korištenjem biblioteke *scikit-learn*, uz optimizaciju hiperparametara primjenom *GridSearchCV*.

3.4 Proces treniranja

Treniranje modela provedeno je korištenjem biblioteke *scikit-learn* u kombinaciji s bibliotekom *imblearn*. Budući da je skup podataka bio neuravnotežen, u proces je uključeno nasumično poduzorkovanje (*engl. undersampling*) kako bi se smanjila zastupljenost dominantne klase i postigla bolja ravnoteža među klasama.

Model je izgrađen unutar procesnog tijeka (*engl. pipeline*), čime se osigurava da se svi koraci obrade podataka i treniranja provode dosljedno i bez curenja informacija.

Procesni tijek je obuhvaćao sljedeće korake:

1. Imputacija – nedostajuće vrijednosti u numeričkim značajkama popunjene su medijanom, čime se smanjuje utjecaj ekstremnih vrijednosti.
2. Standardizacija – sve numeričke varijable standardizirane su pomoću *StandardScaler*-a, tako da imaju srednju vrijednost 0 i standardnu devijaciju 1. Time se omogućuje stabilnije i brže učenje modela.

3. Poduzorkovanje – primijenjeno je nasumično poduzorkovanje radi uravnoteženja broja instanci između klasa.
4. Treniranje klasifikatora – konačni korak bio je treniranje modela logističke regresije.

Za optimizaciju hiperparametara primijenjen je *GridSearchCV* s petostrukom križnom validacijom. Ispitane su različite kombinacije parametara:

1. penalty: L1 i L2 regularizacija,
2. C: vrijednosti 0.1, 1 i 10,
3. solver: *liblinear* i *saga*.

Konačni model odabran je na temelju metrike uravnotežene točnosti (*engl. balanced accuracy*), koja je prikladna u slučajevima s neuravnoteženim klasama.

3.5 Rezultati

Evaluacija modela logističke regresije provedena je na testnom skupu podataka. U Tablici 3.2 prikazane su glavne metrike evaluacije.

Metoda	Vrijednost
Točnost (<i>engl. accuracy</i>)	0.96
Uravnotežena točnost (<i>engl. balanced accuracy</i>)	0.9595
MCC koeficijent	0.9229
ROC AUC	0.9488
PR AUC	0.9689

Tablica 3.2: Rezultati evaluacije modela na testnom skupu.

Klasifikacijski izvještaj

Tablica 3.3 prikazuje rezultate klasifikacijskog izvještaja modela logističke regresije.

Za svaku klasu izračunate su vrijednosti preciznosti (*engl. precision*), odziva (*engl. recall*) i F1-mjere, uz broj primjera u testnom skupu (*engl. support*).

Model je za klasu 0 (nedementni) postigao vrlo visoku točnost, s odzivom od 1.00 (svi zdravi ispitanici ispravno klasificirani) i preciznošću od 0.93. Za klasu 1 (dementni) ostvarena je preciznost od 1.00, dok je odziv nešto niži (0.92), što znači da je nekoliko slučajeva demencije pogrešno klasificirano kao nedementni slučaj


Prosječne vrijednosti (makro i težinski prosjek) kao i ukupna točnost (0.96) potvrđuju da model postiže izbalansirane rezultate na obje klase i da pouzdano razlikuje zdrave od oboljelih ispitanika.

Klasa	Preciznost	Odziv	F1-mjera	Potpura
0 (Nedementni)	0.93	1.00	0.96	38
1 (Dementni)	1.00	0.92	0.96	37
Točnost	0.96 (na 75 uzoraka)			
Makro prosjek	0.96	0.96	0.96	75
Težinski prosjek	0.96	0.96	0.96	75

Tablica 3.3: Izvještaj klasifikacije modela logističke regresije.

Matrica zabune


Na slici 3.1 prikazana je matrica zabune modela. Model je ispravno klasificirao svih 38 nedementnih pacijenata ($TN = 38$) i 34 od 37 dementnih pacijenata ($TP = 34$). Tri dementna pacijenta pogrešno su klasificirana kao nedementna ($FN = 3$), dok nije bilo lažno pozitivnih predikcija ($FP = 0$).



Slika 3.1: Matrica zabune modela logističke regresije.

ROC krivulja


Na slici 3.2 prikazana je ROC krivulja s površinom ispod krivulje (AUC) od 0.95, što ukazuje na odličnu sposobnost modela da razlikuje klase.



Slika 3.2: ROC krivulja modela (AUC = 0.95).

Precision–Recall krivulja


Slika 3.3 prikazuje Precision–Recall krivulju. Prosječna vrijednost preciznosti odziva (AP) iznosi 0.97, što potvrđuje da model pouzdano prepoznaje pozitivnu klasu i rijetko generira lažno pozitivne rezultate.



Slika 3.3: Precision–Recall krivulja modela (AP = 0.97).

Distribucija uravnotežene točnosti

Histogram na slici 3.4 prikazuje distribuciju vrijednosti uravnotežene točnosti dobivenih tijekom križne validacije za sve kombinacije hiperparametara testirane GridSearch metodom. Najbolja vrijednost (0.942) označena je crvenom linijom, što potvrđuje stabilnost modela.



Slika 3.4: Distribucija uravnotežene točnosti u petostrukoj križnoj validaciji.

4 | Primjena dubokog učenja u predikciji Alzheimerove bolesti

U ovom poglavlju prikazan je drugi pristup temeljen na metodama dubokog učenja. Za razliku od prethodnog poglavlja, gdje su analizirani numerički demografski i klinički podaci, ovdje se koriste slikovni podaci dobiveni magnetskom rezonancom mozga. Analiza ovakvih podataka zahtijeva naprednije modele za prepoznavanje složenih uzoraka, pri čemu se posebno koriste konvolucijske neuronske mreže.

Na početku poglavlja opisan je korišteni skup podataka te koraci pripreme podataka, potom arhitektura modela i proces treniranja, a zatim i dobiveni rezultati uz diskusiju o njihovim ograničenjima. Na kraju je prikazana implementacija modela unutar web aplikacije, koja omogućuje jednostavnu primjenu razvijenog sustava u praksi.

4.1 Skup podataka

Za treniranje modela dubokog učenja korišten je OASIS MRI skup podataka (Open Access Series of Imaging Studies), koji je javno dostupan i na mrežnoj platformi Kaggle.

Skup podataka sadrži približno 80 000 MR slika mozga koje su razvrstane u četiri klase koje odražavaju stupanj kognitivnog oštećenja: *non demented*, *very mild demented*, *mild demented* i *demented*. Takva klasifikacija omogućuje istraživanje i detekciju različitih stadija bolesti.

Izvorno dostupne MR snimke bile su pohranjene u formatima *.img* i *.hdr*, a radi lakše obrade konvertirane su u NIfTI format (*.nii*) pomoću softverskog paketa FSL (FMRIB Software Library). Kako bi slike bile pogodnije za treniranje neuronske mreže, dodatno su pretvorene u *.jpg* format. Konačna veličina skupa podataka iznosi oko 1.3 GB.

Za treniranje su korištene slike koje prikazuju 2D presjek mozga. MR snimke su rezane duž z-osi u 256 presjeka, pri čemu su odabrani presjeci od 100. do 160., budući da ti dijelovi mozga sadrže najviše relevantnih informacija za prepoznavanje promjena povezanih s demencijom. Na taj način dobiven je uravnotežen i sadržajan skup podataka koji sadrži dovoljan broj primjera za svaku od klasa.

Konačna podjela klasa izvršena je na temelju metapodataka i vrijednosti CDR ljestvice (*engl. Clinical dementia rating*), što omogućuje precizno mapiranje MR snimki na stupnjeve Alzheimerove bolesti.

Kao što je vidljivo u Tablici 4.1, najveći broj slika pripada klasi Non Demented, dok klasa Moderate Dementia sadrži najmanji broj primjera. Ovakva raspodjela pokazuje značajnu neuravnoteženost među klasama, što predstavlja dodatni izazov u treniranju modela dubokog učenja.

Klasa	Broj slika
Mild Dementia	5 002
Moderate Dementia	488
Non Demented	67 200
Very Mild Dementia	13 700

Tablica 4.1: Raspodjela broja MR slika po klasama u korištenom skupu podataka.

4.2 Priprema podataka

Struktura skupa i učitavanje

Slikovni skup je organiziran u mape po klasama (Mild Dementia, Moderate Dementia, Non Demented, Very mild Dementia) te se učitava pomoću `torchvision.datasets.ImageFolder`.

Podjela na podskupove

Korištena je podjela na skupove za učenje, validaciju i testiranje u omjeru 70 : 15 : 15. Pri tome je zadržan sličan razmjer klasa u svakom podskupu kako bi se izbjegla pristranost i omogućila pouzdanija procjena uspješnosti modela.

Pretprocesiranje i augmentacija

Za skup za učenje korištene su augmentacije poput rotacija, zrcaljenja, manjih translacija te promjena svjetline i kontrasta, nakon čega su slike normalizirane. Dodatno je primijenjeno nasumično brisanje dijelova slike radi povećanja robustnosti modela.

Za validaciju i test koristi se deterministički skup transformacija: `Resize(224×224)`, `ToTensor` i ista normalizacija kao u treningu, bez slučajnih augmentacija.

Balansiranje klasa i uzorkovanje

Zbog izrazito neuravnoteženog skupa (npr. dominantna klasa *Non Demented*), primijenjene su dvije komplementarne strategije:

1. Težine po klasi u funkciji gubitka: iz distribucije klasa izračunate su težine, a funkcija gubitka *CrossEntropyLoss* prilagođena je tako da koristi izračunate težine.
2. Ponderirano uzorkovanje: za *train loader* korišten je *WeightedRandomSampler*, pri čemu su uzorcima iz rjeđih klasa pridružene veće težine. Na taj se način skup uzoraka češće sastoji od podzastupljenih klasa, što pridonosi stabilnijem učenju modela.

Analiza skupa

U pripremi je uključena i pomoćna analiza skupa:

1. Statistika i distribucija klasa: ispis broja slika po klasama i izračun omjera neuravnoteženosti.
2. Detekcija potencijalnih duplikata: identificiranje mogućih duplih datoteka koje mogu uzrokovati curenje informacija (*engl. data leakage*) između podskupova.

Konfiguracija učitavanja podataka

Za treniranje, validaciju i testiranje korišteni su *DataLoader*-i s prilagođenom veličinom skupa uzorka (*engl. batch size*). Za trenirajući skup primijenjen je *WeightedRandomSampler*, čime je osigurano uravnoteženo uzorkovanje klasa, dok su validacijski i testni skup učitani deterministički.

4.3 Arhitektura modela

Za duboko učenje u ovom radu korišten je *ResNet-50*, konvolucijska neuronska mreža iz obitelji *Residual Networks*. Glavna inovacija ovih mreža su *rezidualni blokovi* sa *skip konekcijama*, koji omogućuju prolazak informacija i gradijenata iz ranijih slojeva prema kasnijima. Na taj se način ublažava problem nestajanja gradijenata i omogućuje treniranje vrlo dubokih mreža.

Osnovni gradivni element *ResNet-50* je *bottleneck rezidualni blok*. On se sastoji od tri konvolucijska sloja:

1. sloj 1×1 konvolucije koji smanjuje dimenzionalnost,
2. sloj 3×3 konvolucije koji uči prostorne značajke,
3. sloj 1×1 konvolucije koji vraća dimenzionalnost na izvornu veličinu.

Ulaz se potom zbraja s izlazom bloka (*skip konekcija*), čime se osigurava da se izvorne informacije očuvaju čak i ako konvolucijski slojevi ne nauče nove značajke. Formalno, izlaz bloka može se zapisati kao

$$y = F(x, \{W_i\}) + x,$$

gdje x predstavlja ulaz u blok, $F(x, \{W_i\})$ niz konvolucijskih transformacija s parametrima $\{W_i\}$, a y izlaz bloka.

ResNet-50 sadrži ukupno 50 slojeva, pri čemu se u ranim dijelovima mreže nalaze standardne konvolucije i pooling slojevi, dok većinu arhitekture čine rezidualni blokovi. Na vrhu mreže nalazi se potpuno povezani sloj (*engl. fully connected layer*) koji služi za klasifikaciju.

U ovom radu korišten je unaprijed istreniran model ResNet-50 na skupu *ImageNet*, a potom je prilagođen zadatku klasifikacije stadija Alzheimerove bolesti. Izvorni završni sloj mreže zamijenjen je novim klasifikatorom koji se sastoji od linearnih slojeva, *BatchNorm*, *ReLU* aktivacije i *Dropout* slojeva radi smanjenja prenučenosti modela. Konačni sloj ima četiri izlazna neurona koji odgovaraju klasama: *Non Demented*, *Very Mild Dementia*, *Mild Dementia* i *Moderate Dementia*.

Dodatno, većina slojeva osnovne ResNet arhitekture je zaleđena, dok su trenirani samo završni slojevi klasifikatora. Ovakav pristup prijenosa učenja (*engl. transfer learning*) omogućuje iskorištavanje bogatog znanja modela stečenog na velikom skupu podataka (*ImageNet*), a istodobno prilagodbu specifičnom medicinskom problemu.

4.4 Proces treniranja modela

Treniranje je provedeno u dvije faze. U prvoj fazi pokrenuto je učenje unaprijed istreniranog modela ResNet-50 s prilagođenim klasifikatorom. U drugoj fazi primijenjeno je fino podešavanje (*engl. fine-tuning*) s postupnim odmrzavanjem (*engl. progressive unfreezing*) dubljih slojeva radi poboljšanja generalizacije.

Faza I: početno treniranje

U ovoj fazi korišteni su sljedeći operativni parametri: 15 epoha, veličina uzorka (*engl. batch size*) 32, te treniranje na grafičkoj kartici *NVIDIA GeForce GTX 1650* uz *CUDA* podršku. Kroz 1 891 trenažnu i 406 validacijskih mini-serija po epohi model je brzo konvergirao na razinu od oko 78 % točnosti na skupu za validaciju. Najbolji rezultat u fazi I iznosio je 78,33 % uravnotežene točnosti na validaciji, uz stabilan pad gubitka na učenju i malu razliku između točnosti na učenju i validaciji.

Faza II: fine-tuning s postupnim odmrzavanjem

Nakon početne stabilizacije, pokrenuto je fino podešavanje u trajanju od 10 epoha, s optimizatorom *AdamW* i malom brzinom učenja ($5 \cdot 10^{-6}$, kasnije $4 \cdot 10^{-6}$). Pri-

mijenjeno je postupno odmrzavanje dodatnih slojeva kako bi se povećao broj trenabilnih parametara i dopustila dublja prilagodba reprezentacija. Kroz ovu fazu validacijska točnost se kontinuirano povećavala sa početnih 78,33 % na konačnih 93,65 %, što potvrđuje značajno poboljšanje performansi modela.

Sažetak po fazama


Faza	Epohe	Najbolja val. točnost	Napomena
Početno treniranje	15	78,33 %	stabilna konvergencija
Fine-tuning	10	93,65 %	postupno odmrzavanje slojeva

Tablica 4.2: Sažetak rezultata treniranja po fazama.

4.5 Rezultati

Rezultati nakon inicijalnog treniranja

Na slici 4.1 prikazana je matrica zabune dobivena nakon prvog treniranja modela. Model je postigao ukupnu točnost od 77.28%. Uočljivo je da su klase *Non Demented* i *Very Mild Dementia* relativno dobro prepoznate, dok je prepoznavanje klase *Mild Dementia* i posebno *Moderate Dementia* bilo znatno slabije. Ovi rezultati ukazali su na potrebu za dodatnim prilagodbama modela i strategijama poput postupnog odmrzavanja slojeva.




Slika 4.1: Matrica zabune nakon inicijalnog treniranja modela.

Rezultati i analiza modela

Evaluacija konačnog modela provedena je na testnom skupu podataka. Tablica 4.3 prikazuje klasifikacijski izvještaj s osnovnim metrikama: preciznost (*engl. precision*), odziv (*engl. recall*), F1-mjera i broj primjera po klasi (*engl. support*).

Klasa	Preciznost	Odziv	F1-mjera	Potpora
Mild Dementia	0.74	0.89	0.81	501
Moderate Dementia	0.00	0.00	0.00	51
Non Demented	0.99	0.95	0.97	6697
Very Mild Dementia	0.80	0.91	0.85	1396
Točnost	0.94 (na 8645 uzoraka)			
Makro prosjek	0.63	0.69	0.66	8645
Težinski prosjek	0.94	0.94	0.94	8645

Tablica 4.3: Klasifikacijski izvještaj modela na testnom skupu.



Slika 4.2: Detaljne analize modela nakon konačnog treniranja: matrice zabune, metrike po klasama i napredak učenja.

Analiza po klasama

Detaljna analiza po klasama pokazala je sljedeće:

1. *Mild Dementia*: Model postiže dobar rezultat ($F1=0.81$), ali generira veći broj lažno pozitivnih predikcija.
2. *Moderate Dementia*: Uspješnost klasifikacije je iznimno niska ($F1=0.00$), što ukazuje na nedovoljnu zastupljenost podataka u ovoj klasi.
3. *Non Demented*: Postignuti su izvrsni rezultati ($F1=0.97$), s vrlo visokom preciznošću i odzivom.
4. *Very Mild Dementia*: Rezultati su također dobri ($F1=0.85$), iako se povremeno miješa s klasom *Mild Dementia*.

Analiza najčešćih pogrešaka

Analiza najčešćih pogrešaka (Tablica 4.4) pokazuje da se najveći broj grešaka javlja između klasa *Moderate Dementia* i *Mild Dementia*, te između *Very Mild Dementia* i *Mild Dementia*, što je očekivano zbog bliskih stadija bolesti.

Par klasa	Broj grešaka	Postotak
Moderate → Mild Dementia	26	51.0%
Moderate → Very Mild Dementia	20	39.2%
Moderate → Non Demented	5	9.8%
Mild Dementia → Very Mild Dementia	47	9.4%
Very Mild Dementia → Mild Dementia	68	4.9%

Tablica 4.4: Najčešće pogreške modela pri klasifikaciji.

Sažetak prosječnih performansi

Sažetak prosječnih performansi prikazan je u nastavku:

- Prosječna preciznost: 0.63
- Prosječni odziv: 0.69
- Prosječna $F1$ -mjera: 0.66

Važno je naglasiti da su postignuti rezultati snažno uvjetovani neuravnoteženom distribucijom podataka među klasama. Dok je klasa *Non Demented* bila izrazito dominantna i time omogućila modelu da uči stabilne obrasce, klase *Mild Dementia* i osobito *Moderate Dementia* imale su značajno manji broj primjera. Kao posljedica

toga, model je pokazao slabiju sposobnost razlikovanja ovih rjeđe zastupljenih klasa, što se očituje u niskim vrijednostima metrika za *Moderate Dementia*. Unatoč primijenjenim strategijama balansiranja, ostaje vidljiv problem nedostatka kvalitetnih i dovoljno brojnih podataka za rjeđe klase, što otežava generalizaciju modela na tim slučajevima. Iz tog razloga u web-aplikaciji implementiran je prikaz vjerojatnosti za sve klase osim za *Moderate Dementia*, budući da je točnost modela za tu klasu nedostatna za pouzdanu interpretaciju.

4.6 Primjena modela u web aplikaciji

Kako bi razvijeni modeli bili dostupni krajnjim korisnicima, izrađena je web aplikacija s dvodijelnom arhitekturom. Implementacija je dostupna na GitHub repozitoriju [12].

1. **Backend:** implementiran u okviru *Flask* okvira u Pythonu. Backend upravlja autentikacijom korisnika (JWT tokeni), komunikacijom s bazom podataka (*MongoDB*), te integracijom dvaju modela:

- logističke regresije trenirane na numeričkim značajkama pacijenata,
- dubokog konvolucijskog modela ResNet-50 treniranog na MR slikama.

Za svaku predikciju backend provodi pretprocesiranje ulaza, poziva odgovarajući model, računa vjerojatnosti po klasama i vraća rezultate u strukturiranom JSON formatu.

2. **Frontend:** izrađen u *Angular*-u. Frontend omogućuje registraciju i prijavu korisnika, učitavanje MR slika ili unos numeričkih značajki, te pregled rezultata predikcije. Rezultati se prikazuju vizualno (npr. distribucija vjerojatnosti po klasama, Grad-CAM vizualizacije) i tekstualno (interpretacija rezultata i povijest prethodnih predikcija).

Flask backend fokusira se na logiku i rad s modelima, dok Angular frontend osigurava interaktivan korisnički doživljaj. Predikcije se spremaju u MongoDB bazu, što omogućuje kasniji pregled i analizu povijesti rezultata.

5 | Zaključak

U ovom radu izrađen je prediktivni sustav za detekciju Alzheimerove bolesti koji povezuje strojno učenje temeljeno na numeričkim podacima te duboko učenje primijenjeno na MR slikama mozga.

Model logističke regresije postigao je visoku točnost i uravnoteženost između klasa, dok je ResNet-50 bio uspješniji u prepoznavanju složenih obrazaca na slikama, ali s ograničenjima kod rijetkih klasa poput *Moderate Dementia*. Integracija oba pristupa u web-aplikaciju omogućila je njihovu praktičnu primjenu, uz naglasak na jednostavan prikaz i interpretaciju rezultata.

Glavno ograničenje rada bila je neuravnoteženost podataka, koja je i unatoč korištenim strategijama ostala izražen problem. Unatoč tome, rezultati potvrđuju da metode strojnog i dubokog učenja mogu doprinijeti ranoj detekciji i klasifikaciji Alzheimerove bolesti.

Literatura

- [1] Kaggle, *MRI and Alzheimer's Dataset*.
Dostupno na:
<https://www.kaggle.com/datasets/jboysen/mri-and-alzheimers>.
- [2] Kaggle, *OASIS MRI Dataset*.
Dostupno na:
<https://www.kaggle.com/datasets/ninadaithal/imagesoasis>.
- [3] J. RASMUSSEN, H. LANGERMAN, *Alzheimer's Disease – Why We Need Early Diagnosis*, Degenerative Neurological and Neuromuscular Disease, 2019.
- [4] V. S. DIOGO ET AL., *Early diagnosis of Alzheimer's disease using machine learning*, Alzheimer's Research & Therapy, 2022.
- [5] M. G. ALSUBAIE, S. LUO, K. SHAUKAT, *Alzheimer's Disease Detection Using Deep Learning on Neuroimaging: A Systematic Review*, Machine Learning and Knowledge Extraction, 2024.
- [6] V. PATIL ET AL., *Early prediction of Alzheimer's disease using convolutional neural networks*, Egyptian Journal of Neurology, Psychiatry and Neurosurgery, 2022.
- [7] EIT Health, *Machine learning in healthcare: uses, benefits and pioneers in the field*, 2023.
- [8] Alzheimer's Association, *Earlier Diagnosis*.
- [9] W. ZHANG ET AL., *Artificial intelligence technology in Alzheimer's disease research: a review*, Frontiers in Aging Neuroscience, 2023.
- [10] I. GOODFELLOW, Y. BENGIO, A. COURVILLE, *Deep Learning*, MIT Press, 2016.
- [11] C. M. BISHOP, *Pattern Recognition and Machine Learning*, Springer, 2006.
- [12] L. Maltar, *Alzheimer Prediction – GitHub Repository*, 2025.
Dostupno na: <https://github.com/lanamaltar/alzheimer-prediction>.

Sažetak

U radu je prikazana izrada prediktivnog sustava za detekciju Alzheimerove bolesti primjenom metoda strojnog i dubokog učenja. Model strojnog učenja temeljen na logističkoj regresiji primijenjen je na demografske i kliničke podatke pacijenata, dok je model dubokog učenja zasnovan na arhitekturi ResNet-50, korišten za analizu MR snimki mozga. Dobiveni rezultati potvrđuju da oba pristupa mogu razlikovati zdrave od oboljelih, uz napomenu da prepoznavanje težih stadija bolesti zahtijeva dodatna poboljšanja. Sustav je implementiran u obliku web aplikacije, čime je osigurana njegova praktična dostupnost i mogućnost primjene u stvarnim uvjetima.

Ključne riječi

Alzheimerova bolest, strojno učenje, duboko učenje, logistička regresija, konvolucijske neuronske mreže, prediktivni sustavi, web aplikacija

Development of a System for Alzheimer's Disease Prediction

Summary

This thesis presents the development of a predictive system for detecting Alzheimer's disease using machine learning and deep learning methods. A machine learning model based on logistic regression was applied to demographic and clinical patient data, while a deep learning model, built on the ResNet-50 architecture, was used for the analysis of brain MRI scans. The results confirm that both approaches can distinguish between healthy and affected individuals, with a note that recognizing more advanced stages of the disease requires further improvements. The system was implemented as a web application, ensuring its practical accessibility and potential for use in real-world conditions.

Keywords

Alzheimer's disease, machine learning, deep learning, logistic regression, convolutional neural networks, predictive systems, web application

Životopis

Zovem se Lana Maltar i rođena sam 18. kolovoza 2003. u Osijeku.

Osnovno obrazovanje završila sam u Osnovnoj školi Matije Petra Katančića u Valpovu, nakon čega sam nastavila školovanje u III. gimnaziji u Osijeku, koju sam završila 2022. godine. Potom sam upisala preddiplomski sveučilišni studij Matematike i računarstva na Fakultetu primijenjene matematike i informatike Sveučilišta J. J. Strossmayera u Osijeku.

Uz formalno obrazovanje završila sam i Osnovnu glazbenu školu u Valpovu gdje sam pohađala nastavu klavira te sudjelovala na brojnim međunarodnim natjecanjima.